

大数据技术综述

Grissom | 2025年9月

星环信息科技（上海）有限公司

目录

CONTENTS

- 大数据技术体系
- 大数据技术的演变历程与发展趋势
- 大数据技术应用

大数据技术体系

什么是大数据 - 4V特征

	传统数据	大数据
数据量	GB → TB	TB → PB以上
速度	数据量稳定、增长不快	实时产生处理、年增长率超60%
多样性	结构化数据	结构化、半结构化、非结构化数据
价值	统计报表	机器学习、深度学习

大数据是指超出传统数据库工具收集、存储、管理和分析能力的数据集。与此同时，及时采集、存储、聚合、管理数据，以及对数据深度分析的新技术和新能力，正在快速增长，就像预测计算芯片增长速度的摩尔定律一样。

— McKinsey Global Institute

- ✓ 数据**规模**巨大 (Volume)
- ✓ 数据**类型**多样 (Variety)
- ✓ 生成和处理**速度**极快 (Velocity)
- ✓ **价值**巨大但密度较低 (Value)

什么是大数据技术 - 基本概念

➤ 大数据技术

- 以**Hadoop**/类Hadoop为代表的**大规模分布式**集群技术**体系**

➤ Hadoop

- 一个**开源**技术体系
- 由国际著名的**Apache软件基金会**主持，起源于Google，由Yahoo、Facebook等国际知名IT公司共同开发
- 通过一系列**大规模分布式集群技术**，实现大数据处理的每个环节（采集 → 存储 → 管理 → 计算 → 分析）
- 集群内部、集群之间**精密分工、高度协同**
- 大数据技术体系的**核心和基础**



什么是大数据技术 - Hadoop编年史

阶段	时间	事件
前Hadoop	2002.10	Doug Cutting、Mike Cafarella创建了开源网页爬虫项目 Nutch
	2003.10	Google发表了Google File System论文
	2004.07	Doug Cutting、Mike Cafarella在Nutch中实现了GFS的功能
	2004.10	Google发表了MapReduce论文
	2005.02	Mike Cafarella在Nutch中实现了MapReduce的功能
	2006.01	Doug Cutting加入Yahoo，将Hadoop发展成一个可在网络上运行的系统
	2006.02	Apache Hadoop项目正式启动，并支持MapReduce和HDFS独立发展
	2006.02	Yahoo的网格计算团队采用Hadoop技术
	2006.03	Yahoo建立了第一个用于开发的Hadoop集群
	2006.04	第一个Apache Hadoop版本发布
	2006.11	Google发表了Bigtable论文
	2007.04	Yahoo Hadoop集群发展成两个1000个节点的集群
	2008.01	Hadoop成为Apache顶级项目
	2008.02	Yahoo运行了世界最大的Hadoop应用，宣布其搜索引擎产品部署在一个拥有一万个内核的Hadoop集群上

什么是大数据技术 - Hadoop编年史

阶段	时间	事件
Hadoop	2008.06	Hadoop的第一个SQL框架Hive成为Hadoop子项目
	2008.08	第一个Hadoop商业化公司Cloudera成立
	2008.11	Apache Pig的第一个版本发布
	2009.03	Cloudera推出世界上首个Hadoop发行版——CDH，并完全开放源码
	2009.07	MapReduce和HDFS成为Hadoop子项目
	2010.05	HBase脱离Hadoop项目，成为Apache顶级项目
	2010.09	Hive脱离Hadoop项目，成为Apache顶级项目
	2010.09	Pig脱离Hadoop项目，成为Apache顶级项目
	2011.01	ZooKeeper脱离Hadoop项目，成为Apache顶级项目
	2012.03	HDFS NameNode HA加入Hadoop主版本
	2012.08	YARN成为Hadoop子项目
后Hadoop	2013.11	星环科技发布了国内首个全面支持Spark和Hadoop2.0的大数据基础平台软件——TDH
	2014.02	Spark代替MapReduce成为Hadoop的缺省计算引擎，并成为Apache顶级项目
	2015.10	Cloudera公布继HBase以后的第一个Hadoop原生存储替代方案——Kudu

大数据技术体系 - “ABC” 深度融合的3.0技术体系

ECharts、D3、Cboard等

数据展现

A + B

Hive, **Inceptor**, Spark SQL
(数据仓库 & SQL引擎)

Impala, **ArgoDB**, Presto
(数据集市)

Spark MLlib, Tensorflow, **Sophon**
(人工智能)

数据分析

ElasticSearch, **Search**, Solr
(综合搜索)

Storm, Flink DataStream, Spark Streaming, **Slipstream**
(实时流处理)

MapReduce (批处理计算框架)

Spark Core (高性能计算框架)

计算框架

B + C

YARN, Mesos (资源管理系统)

DC/OS, Kubernetes, **TCOS** (容器化集群操作系统)

资源管理

HBase, **Hyperbase**, Cassandra

Redis

Mongodb

Neo4j, **StellarDB** (分布式No/New SQL数据库)

数据存储与管理

HDFS, **Shiva** (分布式文件系统)

Sqoop, **Transporter**
(结构化数据 & 数据导入导出)

Flume, Kafka
(半结构化 / 非结构化数据 & 数据采集 / 分布式消息队列)

数据采集

电子商务、社交网络、智能硬件等

数据源

ZooKeeper (分布式协调服务)

大数据技术体系 - 开源技术简介

➤ 分布式协调服务Zookeeper

- Google Chubby的开源实现，由Hadoop子项目发展而来
- 高可用、高容错和高性能的分布式协调系统
- 将复杂易错的分布式一致性服务封装起来，形成高效可靠的原语集，并提供简单易用的访问接口
- 为大型分布式系统提供关键、共性、高效和可靠的协调服务
 - ✓ 分布式锁
 - ✓ 统一命名
 - ✓ 配置管理
 - ✓ 集群管理（Master选举、节点上下线监测）
- 大数据开源技术体系的基础组件，无可替代
 - ✓ 开源免费、简单易用、高可用、高容错、高性能
 - ✓ 被HDFS、YARN、Kafka和HBase等技术高度依赖



大数据技术体系 - 开源技术简介

➤ 分布式文件系统HDFS

• 概念

- ✓ Hadoop分布式文件系统 (Hadoop Distributed File System)
- ✓ 在开源大数据技术体系中，地位无可替代

• 特点

- ✓ 高容错：多Block多副本，分布式存储，副本丢失后自动恢复
- ✓ 高可用：NameNode HA，安全模式
- ✓ 高扩展：10K节点规模
- ✓ 简单一致性模型：一次写入多次读取，支持追加，不允许修改
- ✓ 流式数据访问：批量读而非随机读，关注吞吐量而非时间
- ✓ 大规模数据集：典型文件大小GB~TB级（大文件），百万以上文件数量，PB以上数据规模
- ✓ 构建成本低且安全可靠：运行在大量的廉价商用机器上，硬件错误是常态，提供容错机制



大数据技术体系 - 开源技术简介

➤ 分布式NoSQL数据库HBase

• 概念

- ✓ Hadoop Database
- ✓ Google BigTable的开源实现
- ✓ 分布式NoSQL数据库
- ✓ 列式存储：海量半结构化数据
- ✓ 采用HDFS为文件存储系统

• 特点

- ✓ 高并发：支持高并发的写入和点查
- ✓ 高可用：HDFS高可用、Region高可用
- ✓ 高扩展：数据自动切分和分布，可动态扩容，无需停机
- ✓ 海量存储：单表可容纳数十亿行，上百万列



大数据技术体系 - 开源技术简介

➤ 批处理计算框架MapReduce

• 概念

- ✓ 面向批处理的分布式计算框架
- ✓ 编程模型：将程序分为Map、Reduce两个阶段

• 核心思想

- ✓ 分而治之，并行计算
- ✓ 移动计算，而非移动数据

• 特点


- ✓ 高容错：任务失败，自动调度到其他节点重新执行
- ✓ 高扩展：计算能力随着节点数增加，近似线性递增
- ✓ 适用于海量数据的离线批处理
- ✓ 降低了分布式编程的门槛



大数据技术体系 - 开源技术简介

➤ 高性能计算框架Spark

- 由加州大学伯克利分校的AMP实验室开源
- 高性能分布式通用计算框架
 - ✓ Spark Core：基础计算框架（批处理、交互式分析）
 - ✓ Spark SQL：SQL引擎（海量结构化数据的高性能查询）
 - ✓ Spark Streaming：实时流处理（微批）
 - ✓ Spark MLlib：机器学习
 - ✓ Spark GraphX：图计算
- 采用Scala语言开发
- 特点
 - ✓ 计算高效：内存计算、Cache缓存机制、DAG引擎、多线程池模型
 - ✓ 通用易用：适用于批处理、在线分析、流处理、机器学习、图计算等多种场景
 - ✓ 运行模式多样：Local、Standalone、YARN/Mesos



大数据技术体系 - 开源技术简介

➤ 分布式资源管理系统YARN

• 概念

- ✓ Yet Another Resource Negotiator, 另一种资源管理器
- ✓ 为了解决Hadoop 1.x中MapReduce的先天缺陷
- ✓ 分布式通用资源管理系统
- ✓ 负责集群资源的统一管理、作业解析和任务调度
- ✓ 从Hadoop 2.x开始, YARN成为Hadoop的核心组件

• 特点


- ✓ 专注于资源管理和作业调度
- ✓ 通用: 适用各种计算框架, 如MapReduce、Spark
- ✓ 高可用: ResourceManager高可用、计算高可用
- ✓ 高扩展: 与HDFS同步扩展



大数据技术体系 - 开源技术简介

➤ 容器引擎Docker


- 开源的应用容器引擎
- 打包应用及依赖包到一个可移植的容器中，然后发布到任意一台Linux上
- 基于LXC（Linux Container）技术演化而来
- 基于Go语言实现，诞生于2013年，由dotCloud发起



Docker

➤ 容器化集群操作系统Kubernetes

- 开源的容器化集群管理引擎
- 生产级容器编排工具
- 基于Go语言实现，诞生于2014年，由Google发起
- 前身Borg系统在Google内部应用了十几年



虚拟机

大数据技术体系 - 开源技术简介

➤ Hadoop数据仓库&分布式SQL引擎Hive

• 概念

- ✓ Hadoop数据仓库：企业决策支持
- ✓ 分布式SQL引擎：对海量结构化数据进行高性能SQL查询
- ✓ 采用HDFS或HBase为数据存储
- ✓ 采用MapReduce或Spark为计算框架

• 特点

- ✓ 提供类SQL查询语言
- ✓ 支持命令行或JDBC/ODBC
- ✓ 提供灵活的扩展性
- ✓ 提供复杂数据类型、扩展函数、脚本等



大数据技术体系 - 开源技术简介

➤ 分布式搜索引擎ElasticSearch


- 开源的分布式全文搜索引擎
- 基于Lucene实现全文数据的快速存储、搜索和分析
- 处理大规模数据：PB级以上
- 具有较强的扩展性，集群规模可达上百台
- 首选的分布式搜索引擎



大数据技术 vs 传统数据技术

- **大数据技术**：以Hadoop/类Hadoop为代表的大规模分布式集群技术体系
- **传统数据技术**：**RDBMS** (Share-everything, 单机关系数据库) + **RAC** (Share-disk, Real Application Cluster/实时应用集群, 一库多实例, Oracle RAC) + **MPP** (Share-nothing, Massively Parallel Processing/大规模并行处理, 分布式关系数据库, Teradata/GreenPlum)

	大数据技术	传统数据技术
数据类型	结构化、半/非结构化数据	结构化数据
数据规模	GB → TB → PB 以上	GB → TB
系统架构	大规模分布式集群、1000+	集中管理、100~200
处理性能	提升几倍至几十倍	TB以上便达到性能瓶颈
可靠性	关键组件实现高可用 海量数据的多副本冗余备份	取决于关键节点 大规模数据的备份和恢复困难
经济性	运行在普通x86服务器上 软件成本低廉	服务器配置要求很高 软件采购成本及后续费用很高
应用价值	数据分析与挖掘	事务处理、统计报表
业务场景	ABC全部功能场景	数据仓库、数据集市




大数据技术能做什么 - 六大功能场景

主报

离线

- 面向
- 全量的操
- 趋势
- 离线



ID	名称	ID	名称	ID	名称
1	五角场	6	徐家汇	11	大柏树
2	浦东建材市场	7	静安寺-南京路-人民广场	12	娄山关路
3	金沙江路中环路口	8	虹莘路	13	新世界
4	漕河泾	9	金沙江路祁连山路	14	长寿路
5	中山公园	10	陆家嘴		



- 实时刷卡信息（来自银联）
- 定义商圈
- 商圈聚类模型分析与选择
- 模型拟合
- 动态商圈区域即时呈现，收缩变化一目了然
- 二级商圈的挖掘
- 人群密度趋势研判

应用层


功能层

技术层

客服


炼化厂

大数据技术如何落地 - 基于产品体系构建解决方案



大数据技术演变历程与发展趋势


大数据技术演变历程



- 星环在世界上**首先提出“Big Data 3.0”概念**，并指出其核心就是**构建“ABC”深度融合的新型大数据技术体系**，并以此为**基础，打造覆盖“ABC”全部业务场景的一站式综合平台**，以满足客户的多元化、复杂化需求，同时降低开发、管理和使用复杂度，提高用户体验
- 星环领先于国内外大数据厂商，**率先推出“ABC”融合的平台产品「TDH + Sophon + TDC」**

Big Data 3.0: 大数据技术发展趋势

➤ 核心特征: **AI + BigData + Cloud** 走向深度融合 → 智能化 + 云服务化 + 融合化




Big Data 3.0: 大数据技术发展趋势

➤ 智能化：分布式人工智能算法

类别	数量	算法
分类	9	XGBoost, Random Forest, etc
回归	7	Isotonic regression, survival regression, etc
聚类	3	Gaussian Mixture Model, etc
时间序列	3	AutoRegression、ARIMA, LSTM
统计	>12	Common statistical methods
推荐	5	ALS、FM、CF based
关联分析	5	FP-Growth, PrefixSpan
深度学习	13	Common neural network
自然语言处理	14	New Word Detection, Named-entity recognition, etc
图像处理	4	Common network

Big Data 3.0: 大数据技术发展趋势

智能化：机器学习全流程支持



weighted recall: 0.92 +/- 0.0

	true 9	true 5	true 1	true 6	true 8	true 0	true 7	true 2	true 3	true 4	class pre...
pred 9	7	0	0	0	0	0	0	0	0	0	100.00%
pred 5	0	13	0	0	0	0	0	0	0	0	100.00%
pred 1	0	0	7	0	0	0	0	0	0	0	100.00%
pred 6	0	0	0	10	0	0	0	0	0	0	100.00%
pred 8	0	0	0	0	12	0	0	0	0	0	100.00%
pred 0	0	0	0	0	0	8	0	0	0	0	100.00%
pred 7	0	0	0	0	0	0	10	0	1	0	90.91%
pred 2	0	1	0	1	2	0	0	6	2	0	50.00%
pred 3	0	0	0	0	0	0	0	1	13	0	92.86%
pred 4	0	0	0	0	0	0	0	0	0	6	100.00%
class recall	100.00%	92.86%	100.00%	90.91%	85.71%	100.00%	100.00%	85.71%	81.25%	100.00%	

数据导入

数据探索





数据预处理

特征工程

模型训练

性能验证

模型部署



Big Data 3.0: 大数据技术发展趋势


➤ 云服务化：容器化的弹性资源管理和调度，为大数据上云奠定了基础

容器化集群操作系统


资源池化

利用容器技术统一管理和调度资源


支持弹性扩展



CPU




GPU



内存



存储



网络

.....

Big Data 3.0：大数据技术发展趋势

➤ 云服务化：在云端提供完整的大数据产品线



Big Data 3.0: 大数据技术发展趋势

➤ 融合化：架构融合，利用统一架构替换混合架构

统一架构

Transwarp

~~混合架构~~

MPP

Teradata / HP Vertica
GreenPlum / PG-XL

- 具备一定的并行处理能力
- 能够处理中等规模关系数据，但无法处理大规模数据，10TB是瓶颈
- 无法处理半/非结构化数据
- 扩展性较差，集群规模100~200
- 并发度较低，50~100
- 时效性较差
- 场景较单一，无法支撑多样化、智能化分析场景

RDBMS+RAC

Oracle / MySQL / PG

- 无法处理半/非结构化数据
- 只能处理小规模关系数据 (<100GB)
- 并发度低，无法支撑集团客户
- 时效性差，大多为T+N方案，难以同时支撑离线和在线业务
- 场景单一，主要是报表，难以实现文本分析、图像识别等智能场景

MPP + Hadoop

- 架构复杂，导致架构设计、项目实施和集群运维的成本显著增加
- 数据冗余，数据需存储多份，导致硬件成本显著增加
- 数据链路过长，数据从产生到使用经历的环节大幅增加，数据时效性的保证成本较高
- 数据一致性较难保证

- 采用类Hadoop架构，有效解决混合架构的问题
- 避免混合架构带来的复杂度，降低软硬件和人力成本
- 数仓数集一体化设计，减少数据链路，增加资源复用性，提高时效性


Big Data 3.0: 大数据技术发展趋势

➤ 融合化：平台融合，统一了数据湖、数据仓库和数据集市




Big Data 3.0: 大数据技术发展趋势

➤ 融合化：服务融合，分析及服务，统一弹性的分析服务调度和管理



Big Data 3.0: 大数据技术发展趋势

➤ 融合化：管理融合，统一的数据、模型和应用管理




Big Data 3.0: 大数据技术发展趋势

➤ 融合化: 开发方式融合, SQL + R/Python



Big Data 3.0: 大数据技术发展趋势

➤ 融合化：工具融合，完整的BI+AI工具栈，支持数据处理的全生命周期



ETL tools - Transporter



Data governance software - Governor



Reporting tool - Pilot

数据探索

数据整合

数据预处理
/ 特征工程

数据管理

数据建模

数据可视化


模型管理

列名	数据类型	描述
cust_id	varchar(20)	客户ID, 主键
cust_name	varchar(100)	客户名称
cust_region	varchar(20)	客户地区
cust_manager_name	varchar(100)	客户经理姓名
cust_email	varchar(100)	客户邮箱
cust_phone	varchar(20)	客户电话
cust_address	varchar(200)	客户地址


Data Catalog



Job Design & Scheduling Tool - Workflow



Sophon visual modeling



Sophon Model Service

Big Data 3.0：大数据技术发展趋势

➤ 融合化：数据 + 服务 + 应用融合，三者相互促进，产生闭环，构建企业数据生态

• 大数据PaaS平台

- 支持多租户
- 支持服务治理
- 支持安全管控

• 数据资产管理

- 帮助企业将内部数据归一化、资产化
- 统一的数据质量标准和接入标准
- 通过机器学习的方式来梳理数据
- 为价值创造提供先决条件

• 数据服务治理

- 提供有效的客户应用上架和管理服务
- 可以在整个平台里开发、测试、部署
- 使用数据的资产、创造价值以及新的数据资产



• AI模型工厂

- 帮助用户有效的创造和共享机器学习和AI模型
- 让机器学习和人工智能平民化，普惠化



大数据技术应用

春秋航空大数据平台



挑战:

1. 航班每次飞行的耗油占总成本的**30%-40%**, 降低油耗可有效提升盈利能力。
2. 随着数据量的增加, **原CDH集群**的业务处理速度有极大的限制, 无法满足实时要求。
3. 数据分别存储在CDH/Oracle/Mysql中, 迫切需要将用户行为**数据打通**, 以降低系统运维成本。

解决方案:


1. Inceptor作为构建大数据企业级数仓的关键组件, 支持SQL和PL/SQL语法, 支持分布式事务, 满足客户批处理性能需求。
2. 使用流处理引擎Slipstream进行线上日志的实时解析比对和处理, 可满足实时处理场景。
3. 基于大数据平台的节能减排应用: **快速发现潜在的直飞航路**, 减少飞行距离, 达到节油目的; 通过对历史飞行轨迹及油耗分析, **寻找飞机携带油量的平衡点**; **发现计划层、飞行高度层和最佳高度层之间的差异**, 辅助优化飞行过程, 最终实现节能降耗, 高度绿色飞行。

项目成果:

1. 大数据平台上线后, 实现 workflow 调度批处理业务, 可进行在线日志的实时解析, 实现快速批处理业务, 提供稳定高效的批处理性能, 以及高并发, 且支持全文索引下的毫秒级查询。
2. 空中小时耗油平均**降低20kg/小时**, 对于一个80架飞机机队规模的航司, 年飞行300,000小时, 累计可为公司**节约2400万元**。
3. 系统上线四个月, 成本指数执行率**从58%提升至69%**, 国际航线能够**提升至80%以上**。



春秋航空



春秋航空是一家倡导旅客个性化消费的航空公司

温故知新

- 请简述大数据的基本特征及含义。
- Hadoop经历了几个发展阶段，各有什么特点和里程碑事件？
- 如何理解大数据技术体系的二维矩阵设计思想？
- MPP与大数据技术的本质区别是什么？
- 数据平台架构经历了几个发展阶段，为什么要走向统一？
- 请简述Big Data 3.0的基本含义和核心特征。



Thanks

www.transwarp.io

星环信息科技（上海）有限公司 版权所有

公司地址 / Our Office

上海：徐汇区虹漕路88号越虹广场B座11F&12F

北京：海淀区西直门北大街甲43号金运大厦B座1101室

广州：天河区体育东路140-148号南方证券大厦1015-1016室

联系电话：4007-676-098