

数据仓库&数据集市概述

Grissom | 2025年12月

目录 >

CONTENTS

- 1 数据仓库概念
- 2 数据仓库基本架构
- 3 数据集市概念
- 4 数据仓库模型设计




1 chapter

数据仓库概念

- ✓ 概念
- ✓ 专注分析

➤ 自然演化式体系结构：企业内由抽取程序编织的蛛网



！ 问题

- 数据可信性
 - ✓ 数据无时间基准
 - ✓ 抽取的多层次问题
 - ✓ 外部数据问题
 - ✓ 无公共起始数据源
 - ✓ 数据算法上的差异
- 生产率
 - ✓ 数据、问题定位难
 - ✓ 多标准、数据获取难
 - ✓ 复用率低
- 难以将数据转化为信息
 - ✓ 非集成化
 - ✓ 没有足够的历史数据

- 数据仓库（Data Warehouse, DW）：体系结构的改变
- 数据仓库是一个面向主题的、集成的、非易失的、反应历史变化的、用来支持企业管理决策的数据集合




➤ 数据仓库特点

1. 面向主题 Subject Oriented

数据仓库中的数据是按照一定的主题域进行组织。


主题是指用户使用数据仓库进行决策时所关心的重点方面，一个主题通常与多个操作型信息系统相关。



➤ 数据仓库特点

2. 集成 Integrated

数据仓库中存储的数据是来源于多个数据源的集成，原始数据来自不同的数据源，存储方式各不相同。要整合成为最终的数据集合，需要从数据源经过一系列抽取、清洗、转换的过程。




➤ 数据仓库特点

3. 非易失 Non-Volatile

数据仓库中保存的数据是一系列历史快照，不允许被修改。

用户只能通过分析工具进行查询和分析。




➤ 数据仓库特点

4. 随时间变化而变化 Time Variant (时变性)

数据仓库的数据是随时间而变化的，会定期接收新的集成数据，从而反应出最新的数据变化。

但稳定的数据是以只读格式保存，且不随时间改变。



➤ 数据仓库 VS 数据库

- 数据库是面向事务的设计，设计目的是为了捕获数据，一般存储在线交易数据，并且在设计时尽量避免冗余，常采用符合范式的规则来设计。
- 数据仓库是面向主题设计的，设计目的是为了分析数据，一般存储的是历史数据，但在设计时有意引入冗余，采用反范式的方式来设计。


数据库		数据仓库
面向	事务	分析
数据类型	细节、业务	综合、清洗过的数据
数据特点	当前的、最新的	历史的、跨时间维护
目的	日常操作	长期信息需求、决策支持
设计模型	基于ER模型，面向应用	星形/雪花模型，面向主题
操作	读/写	大多为读
数据规模	GB到TB	>=TB

➤ ETL -- Extract-Transform-Load

将数据从来源端经过抽取（extract）、交互转换（transform）、加载（load）至目的端的过程。

是构建数据仓库的重要一环，用户从数据源抽取出所需的数据，经过数据清洗，最终按照预先定义好的数据仓库模型，将数据加载到数据仓库中去。

- Logstash
- Kettle
- Kafka
- Sqoop
- ...



➤ 数据仓库专注分析、为企业决策提供支持

- 某保险集团有多条业务线，包括人寿保险、汽车保险、房屋财产险、健康保险、养老保险等等。各个业务线的正常运营需要记录和维护很多信息，包括客户、保单、收付费、核保、理赔等等。



能否基于业务系统作进行数据分析？



ID	0001
name	Allen
category	国寿盛世
amount	8（千）

ID	241568
name	Allen
category	居家无忧
amount	98（元）

ID	456621
name	Allen
category	车损险
amount	19.6（万）

ID	200145
name	Allen
category	幸福一生
amount	4200（元）

➤ 数据仓库专注分析、为企业决策提供支持


- 某保险集团有多条业务线，包括人寿保险、汽车保险、房屋财产险、健康保险、养老保险等等。各个业务线的正常运营需要记录和维护很多信息，包括客户、保单、收付费、核保、理赔等等。

人寿险		财险		车险		养老险	
Oracle		Mysql		Oracle		SqlServer	
ID	0001	ID	241568	ID	456621	ID	200145
name	Allen	name	Allen	name	Allen	name	Allen
category	国寿盛世	category	居家无忧	category	车损险	category	幸福一生
amount	8（千）	amount	98（元）	amount	19.6（万）	amount	4200（元）



➤ 数据仓库专注分析、为企业决策提供支持

- 为了更全面的进行各种规模数据的分析，同时不影响业务应用系统的正常运行，所以需要构建一个统一的、集成的、专门用于分析的数据平台






2 chapter

数据仓库基本架构

- ✓ 数仓分层架构
- ✓ 为什么要分层

➤ 数据仓库基本分层结构



➤ 缓冲层（数据接入层）



➤ 为什么要分层

- 数据仓库中的数据要想真正发挥最大的作用，必须对数据仓库进行分层，数据仓库分层的优点如下：
 - **把复杂问题简单化**。可以将一个复杂的任务分解成多个步骤来完成，每层只处理单一的步骤。
 - **减少重复开发**。规范数据分层，通过使用中间层数据，可以大大减少重复计算量，增加计算结果的复用性。
 - **隔离原始数据**。使真实数据与最终统计数据解耦。
 - **用空间换时间**。通过大量的预处理来提升应用系统的用户体验、分析效率。



3 chapter

数据集市概念


- ✓ 概念
- ✓ 数据集市分类
- ✓ OLAP
- ✓ 数据集市 VS 数据仓库

➤ 数据集市(Data Mart)

- 数据集市（Data Mart）是一个针对某个主题、某个部门或者某些特殊用户而进行分类的数据集合，也称为“小数据仓库”或“部门级的数据仓库”

- 特点：

- 满足特定部门或用户需求
- 针对特定主题
- 统一的高质量数据
- 数据仓库的子集
- 交互式分析、秒级返回




➤ 独立型数据集市：自下而上开发

- 从数据集市入手，就某一个特定的主题，先做独立数据集市，当数据集市达到一定规模，再从各个数据集市进行数据的整合建立企业级的数据仓库
- 数据集市包含了能够从数据源获取的全部的明细数据
- 是为了支撑某个业务流程而建立的维表集合
- 数据集市是基于数据来源而非部门的视图
- 优点
 - 搭建快、成本低、风险小


• 缺点：

- 可能会导致信息孤岛的存在，不能以全局的视角去分析数据、可能会存在大量冗余数据



➤ 从属型数据集市：自上而下开发

- 从属型数据集市采用自上而下的开发方式。首先建立企业级的数据仓库，然后从企业级的数据仓库中为各个部门抽取必要的数据建立部门级的数据集市
- 数据仓库中保存了企业的颗粒化数据，可作为事实的唯一版本
- 优点：
 - 体系结构上更稳定
 - 可以提高数据分析的质量，保证数据的一致性
- 缺点：
 - 实施周期长、难度大、风险高



➤ OLAP (Online Analytical Processing) 联机分析处理

➤ 一种**多维分析技术**

➤ 帮助分析人员、管理人员或执行人员**快速、交互式的**从**多方面**了解并观察数据，从而深度掌握其中的信息

➤ 具有FASMI，即共享多维信息的快速分析的特征
(Fast Analysis of Shared Multidimensional Information)

➤ 数据集中字段，按照用途可划分为：

- **维度**：描述事实记录的特征属性，是分析数据的一种角度
维度由层次、级别、属性构成。

- **度量 (事实)**：对事实记录反映出的数据，是待分析数据对应数值字段的统称




➤ ROLAP (Relational OLAP)

- 基于关系型数据库的OLAP实现
- 以关系数据库为核心，以关系型结构进行多维数据的表示和存储。
- 传统模式中，将多维结构划分为两类表：
 - 1、事实表 —— 用来存储数据和维关键字;
 - 2、维表 —— 即对每个维至少使用一个表来存放维的层次、成员类别等维的描述信息。
- 技术特点：
 - 传统模式中，细节数据保留在关系型数据库的事实表，聚合后的数据也保存在关系型数据库


➤ MOLAP (Multidimensional OLAP)

- 基于多维数据组织的OLAP实现
- 多维数据在存储中将形成 “**立方块 (Cube)**” 的结构



➤ 技术特点:


- 细节数据和聚合后的数据均保存在cube中
- 以空间换效率，查询时效率高
- 生成cube时需要大量的时间和空间



维度爆炸

-- 在所有基于预计算的OLAP应用中，维度爆炸都是一个广为诟病的问题。

- 对于原始的未经任何优化的Cube来说，用户关注的任意一个表中的Cloumn或Column表达式即是一个维度。Cube预计算会对维度进行组合，当Cube具有n个维度时，可能的维度组合是 2^n 个，预计算产生的物化表将是 2^n 张。当Cube维度变成m+n时，物化表的个数急剧地增加到 $2^{(m+n)}$ ，呈**指数级爆炸式增长**。



➤ ROLAP 对比 MOLAP

➤ ROLAP:


- 优势：可以处理大数据量数据集，且不需要物化预计算结果来额外占用存储空间
- 劣势：当处理过滤率不高、参与计算数据量大时，性能可能会有所减慢

➤ MOLAP:

- 优势：将细节数据和聚合后的数据均保存在cube中，**以空间换效率**，查询时效率高
- 劣势：需要对预先生成的cube进行物化，会额外占用大量的存储空间

➤ 数据集市(Data Mart) VS 数据仓库 (Data Warehouse)

对比项	数据仓库	数据集市
范围	企业级	部门级或业务线
主题	企业主题	部门或特殊的分析主题
数据源	遗留系统、事务系统、外部数据等多个数据源	数据仓库或事务系统的少量数据源
数据粒度	较细的粒度	较粗的粒度
数据结构	通常是规范化结构（3NF）	星形模型、雪花模型或两者混合
历史数据	大量的历史数据	适度的历史数据





4 chapter

数据仓库模型设计

- ✓ 数据模型
- ✓ 关系模型 vs 维度模型

➤ 模型 – Model

- 模型是指对于某个实际问题或者客观事物、规律进行抽象后的一种形式化表达方式
- 比如地图、建筑设计沙盘、模型飞机等等.....
- 模型的建立为某些领域，带来了更多实际的意义

➤ 数据模型DM – Data Model

- 数据模型一般多指在设计和建立数据库时，用于提供数据表示和操作手段的形式架构
- 使用数据模型，可以提供一些良好的特性，以适应特定场景

➤ 企业数据模型EDM – Enterprise Data Model

- 企业数据模型是企业数据特征的抽象，主要用来体现企业的业务规则以及信息
- 通过图形的实体和关系方式反映一个业务过程，是进行数据管理、分析和交流的重要手段，是模型、ETL、业务人员沟通的桥梁

➤ 为什么需要数据模型

- 随着互联网、智能设备及其他信息技术的发展，数据爆发式增长，如何将数据进行有序、有结构地分类组织和存储是当下面临的挑战



没有数据模型，就如杂货铺，有了数据模型，就如麦德龙、宜家等大商场，让货架上货物可以摆放有序、整齐，方便挑选









从使用数据模型者的角度来看，数据模型好比一张地图，通过地图导航，方便数据使用者迅速、高效找到所需要的数据

➤ 数据模型的层次

- 定义了重要的业务概念和彼此的关系
- 由核心实体或其集合，及实体间的业务关系组成
- 类似行业数据模型

- 对概念数据模型的进一步分解和细化
- 描述实体、属性、以及实体与实体之间的关系

- 描述模型实体的细节，对数据冗余与性能进行平衡
- 关注数据库的物理实现，解决细节技术问题
- 需要考虑数据类型、长度、索引等因素
- 需确定数据平台和架构



➤ LDM与PDM

- **逻辑数据模型（Logical Data Model，即LDM）**是数据仓库在数据建设阶段为解决业务需求而定义的模型解决方案，是战略层面的，主要决定模型的总体架构，它是连接数据仓库的数据与最终用户之间的逻辑桥梁，但它还不能直接拿来实施，它并不是数据仓库数据的真实物理反映。
- **物理数据模型（Physical Data Model，即PDM）**是基于逻辑数据模型的物理化，它是在继承逻辑模型设计框架和原则的基础上，针对系统性能和应用需求而进行的适当的非范式化的物理模型设计，它更着眼于实施、操作和性能，更贴近数据，它是数据仓库数据的真实物理反映。

➤ LDM与PDM

• 相同点


- 主题一致、主体结构一致、主要实体一致和主要字段相同
- PDM继承了LDM的灵活性，易于扩展等优点
- LDM有利于业务人员和最终用户对PDM的理解
- LDM是PDM成功实施的基础性保障

• 不同点

- PDM更着眼于实施、操作和性能，更贴近数据
- PDM需要经常性的维护
- PDM更多的考虑系统物理特性
- PDM更多的考虑数据处理性

```
/*=====*/
/* Table: t_individual
/* Definition: 自然人信息
/*=====*/
DROP TABLE IF EXISTS t_individual;
CREATE TABLE t_individual (
  indiv_id VARCHAR(20) COMMENT '自然人编号' NOT NULL,
  indiv_nm VARCHAR(10) COMMENT '姓名',
  open_dt DATE COMMENT '开户日期',
  indiv_stat CHAR(2) COMMENT '自然人状态',
  cancel_dt DATE COMMENT '销户日期',
  gender VARCHAR2(2) COMMENT '性别',
  birthday DATE COMMENT '出生日期',
  ident_no VARCHAR(60) COMMENT '证件号码',
  mobile_no VARCHAR2(11) COMMENT '手机号',
  email_address VARCHAR(50) COMMENT '邮箱',
  tel VARCHAR2(11) COMMENT '固定电话',
  address VARCHAR2(100) COMMENT '家庭住址',
  src_sys_cd VARCHAR(20) COMMENT '源系统代码',
  src_sys_nm VARCHAR(60) COMMENT '源系统名称',
  etl_job VARCHAR(60) COMMENT '加载作业',
  etl_first_time TIMESTAMP COMMENT '加载时间',
  etl_upd_time TIMESTAMP COMMENT '更新时间'
)
COMMENT '自然人信息'
PARTITIONED BY RANGE (open_dt) (
  PARTITION before2020 VALUES LESS THAN ("2020-01-01"),
  PARTITION before2021 VALUES LESS THAN ("2021-01-01"),
  PARTITION before2022 VALUES LESS THAN ("2022-01-01")
)
CLUSTERED BY (indiv_id) INTO 7 BUCKETS
TBLPROPERTIES ('holodesk.index'='indiv_stat');
```

- 关系数据模型的规范化是一种组织数据的技术
 - 规范化方法对表进行分节，以消除数据冗余，避免异常更新，提高数据完整性
 - 通过实体关系（E-R）描述企业业务和业务规则



- ✓ **实体**
客观存在并且可以相互区别的事物称为实体
- ✓ **关系**
描述实体间的关联性，实体间的关系基本上有三种：一对一，一对多，多对多
- ✓ **属性**
一个属性是在数据模型中用来描述一个事物的最基本元素。是描述一个事物或交易在数据元素级上的抽象定义

➤ 关系模型 – 3NF

- 在范式理论上符合3NF
 - 每个属性值唯一，不具有多义性；
 - 每个非主属性必须完全依赖于整个主键，而非部分主键；
 - 每个非主属性不能依赖于其他关系中的属性，
因为这样的话，这种属性应该归到其他关系中去。
- 数据仓库中的3NF与OLTP系统中的3NF的区别在于，它是站在企业角度面向主题的抽象，而不是针对某个具体业务的抽象。
- 优点：模型稳定、相对简单
- 典型行业：传统金融、证券行业，如银行

学号	姓名	所属系	课程	成绩
20010010001	小明	法律系，王强	刑法	85分
20010010001	小明	法律系，王强	民法	75分

学号	姓名	所属系	系主任	课程	成绩
20010010001	小明	法律系	王强	刑法	85分
20010010001	小明	法律系	王强	民法	75分

学号	课程	成绩
20010010001	刑法	85分
20010010001	民法	75分

学号	姓名	所属系	系主任
20010010001	小明	法律系	王强

学号	课程	成绩
20010010001	刑法	85分
20010010001	民法	75分

学号	姓名	所属系
20010010001	小明	法律系

系名	系主任
法律系	王强

➤ 维度模型

- 维度模型一种趋于支持最终用户的、从**分析决策的需求**出发的数据模型
- 关注用户如何更快速地完成需求分析，同时具有较好的大规模复杂查询响应能力
- 特点：易理解、高性能、易扩展
- 维度模型将表分为维度表和事实表：
 - 维度表(Dimension)：对数据进行分类的表，用于从特定的角度观察数据。维度是事实表的入口点或链接，充当“查询”或“报表”约束的主要来源；维度通常是高度反范式的，通常占总数据的10%左右。例如：时间、地区、产品等
 - 度量表(Measure)：又叫事实表(Fact)，是维度建模中最基本的表，存放业务度量数据，例如数量、金额、汇总等流水和快照数据

➤ 维度模型 —— 事实表

- 数仓/数集维度建模的核心，围绕业务过程进行设计
- 通过获取表述业务过程的度量来表达业务过程
- 包含了应用的维度和与业务过程有关的度量
- 基础结构：
 - 一个或者多个数值型的度量字段，我们称之为事实（Fact）
 - 一组关联到维表的外键，而这些维表提供了事实表度量的上下文
 - 一个或者多个退化维度(Degenerate Dimensions)
 - ✓ 退化维度存在于事实表，但是他们不是外键，不关联任何真正的维表
 - ✓ 可能会是事实表的主键

零售交易事实表	
日历日 (FK)	→
产品 (FK)	→
出纳登记簿 (FK)	→
客户 (FK)	→
员工 (FK)	→
商店经理 (FK)	→
价格范围 (FK)	→
促销折扣 (FK)	→
交易类型 (FK)	→
付款方式 (FK)	→
发票号 (DD)	
行号 (DD)	
时间戳 (SQL Date-Time)	
零售数量 (fact)	
零售额净利 (fact)	
折扣金额 (fact)	
成本金额 (fact)	
总利润额 (fact)	
税金 (fact)	

➤ 维度模型 —— 维度表

- 维表提供了事实表的上下文；维表通常比事实表小得多；提供了查看数据的入口。

- 基础结构：

- 代理键：

- ✓ 一个无意义的，唯一标识的字段

- ✓ 维表的主键，事实表的外键

- 自然键：


- ✓ 一个或多个字段

- ✓ 从源系统抽取来的有意义的字段

- 描述属性：



- ✓ 静态或者变化比较慢的字段

- ✓ 会有多个



➤ 维度模型 —— 事实表 & 维度表

• 示例:




➤ 星型模型

- 表达维度和事实之间单层关系的模型
- 事实和每个维度之间都是直连关系
- 不同维度之间没有任何关联

- 优点:

- 简化查询
- 简化业务报表逻辑
- 提升查询性能
- 快速聚合
- 便于向立方体提供数据




➤ 雪花模型

- 基于星型模型之上拓展来的
- 一般是对星型模型的维度表进行了范式化，一个维度被规范化成多个关联的表
- 一个规范化的维度对应一组具有层次关系的维度表，表达维度和事实之间多层关系

- 优点：

- 规范化的维度属性节省存储空间。



➤ 关系模型还是维度模型

- 无统一标准：不同的场景、不同的客户，选择结果会有所不同




关系模型

优点：模型稳定简单、低冗余

缺点：友好性和性能弱

适用场景：传统金融行业



维度模型

优点：易理解、性能好

缺点：稳定性弱、高冗余

适用场景：互联网行业



Q&A

TRANSWARP
星 环 科 技